

Mobilidade Urbana e Transporte Público

Como o clima e o volume de veículos influenciam o tempo médio de deslocamento?

Tema: Mobilidade urbana e transporte público

Integrantes: Gabriel

Lívia Fernanda

Curso: Bacharelado em Ciência da Computação

Seminário II — 2025

Problema e Impacto

O aumento dos congestionamentos e das chuvas causa atrasos significativos no transporte público das grandes cidades.

Pergunta central:

Como o fluxo de veículos e o clima afetam o tempo médio e a pontualidade dos ônibus?

Por que é importante:

- Afeta diretamente a **mobilidade urbana** e a **qualidade de vida**.
- Gera **custos** e **emissões** adicionais.
- Dados abertos permitem **soluções baseadas em evidências**.

Objetivos

Objetivo geral:

Analisar e prever fatores que impactam o tempo médio de deslocamento no transporte público urbano.

Objetivos específicos:

- 1 Coletar e integrar dados de tráfego e clima
- 2 Identificar padrões de atraso e congestionamento
- 3 Treinar modelos de regressão para previsão de tempo de deslocamento
- 4 Propor recomendações para otimização da frota e horários

Fontes de Dados

Principais fontes utilizadas:

- **SPTTrans / GTFS** — Horários, rotas e pontualidade dos ônibus.
- **INMET / API Climática** — Chuva, temperatura, vento.
- **Prefeitura / Waze for Cities / [Dados.gov.br](https://dados.gov.br)** — Volume de veículos e congestionamentos.
- **IBGE / OpenStreetMap** — Regiões e georreferência.

Período: Janeiro–Agosto de 2025

Granularidade: Região × Hora

Metodologia (Pipeline)

Etapas da Ciência de Dados:

01

Coleta e limpeza (ETL)

Padronização de dados, remoção de nulos/outliers.

02

Análise exploratória (EDA)

Estatísticas, correlações, gráficos.

03

Modelagem preditiva

Regressão (Random Forest / Linear Regression).

04

Visualização e storytelling

Dashboards interativos (Plotly).

05

Recomendações práticas

Baseadas nos insights dos dados.



Principais Descobertas (EDA)

Insights identificados:

Dias de chuva

Aumentam o tempo médio de deslocamento em até **18%**.

Horários de pico

7h–9h e 17h–19h concentram mais de **60% dos atrasos**.

Densidade de veículos

Regiões com maior densidade apresentam **baixa velocidade média (<15 km/h)**.

Correlação chuva-velocidade

Forte correlação entre **chuva e redução da velocidade média**.

Modelagem e Resultados

Modelo utilizado: Random Forest Regressor

Variáveis preditoras: volume de veículos, chuva, temperatura, hora, região.

Variável alvo: tempo médio de deslocamento (minutos).

Métricas:

0.82

R^2

3.4

MAE (min)

4.9

RMSE (min)

Feature importance:

1. Volume de veículos
2. Chuva (mm/h)
3. Hora do dia
4. Região

Dashboard / Protótipo

Protótipo desenvolvido:

Dashboard interativo em **Plotly Dash / Power BI**.

Filtros:

Data, hora, clima, região.


Indicadores:

- Tempo médio de deslocamento.
- Viagens atrasadas (%).
- Velocidade média.


Mapa interativo com congestionamentos e pontos críticos.

Gráficos Ilustrativos


Consolidar as principais métricas e visualizações em um painel interativo para apoiar decisões sobre mobilidade urbana.




**Tempo de Deslocamento x
Volume de Veículos por Região**



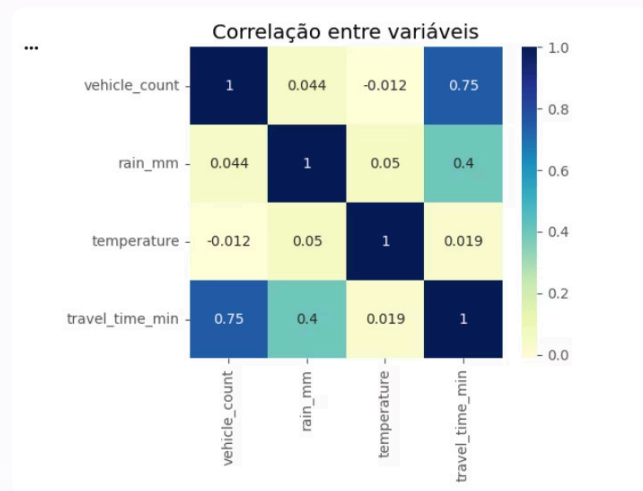
Importância das Variáveis




**Relação entre Volume de
Veículos e Tempo de
Deslocamento**



Tempo médio por chuva




Correlação entre Variáveis



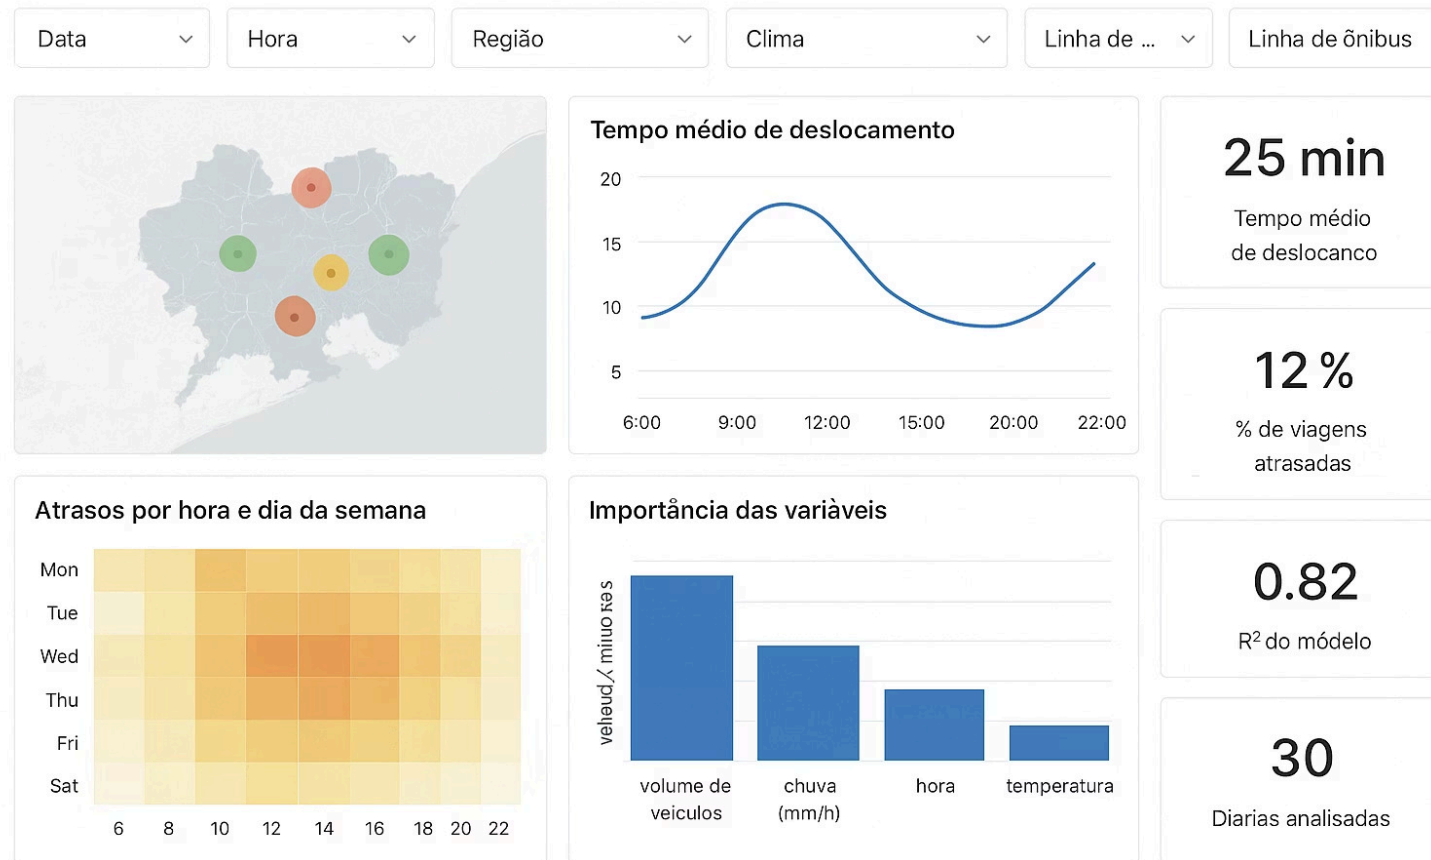
Efeito da Chuva no Tempo de Deslocamento

Tempo Médio e Deslocamento por Hora



Dashboard Interativo de Mobilidade e Transporte público

Dashboard interativo de mobilidade e transporte público



Recomendações Práticas

Com base nos dados:

→ **Ajustar oferta de ônibus**

Em horários de pico e dias de chuva.

→ **Integrar previsão de clima**

Ao planejamento de frota.

→ **Priorizar faixas exclusivas**

Em regiões críticas.

→ **Disponibilizar informações em tempo real**

Aos usuários.

Impacto esperado:

- Redução de atrasos e emissões.
- Maior eficiência operacional.
- Melhor experiência dos passageiros.

Limitações e Próximos Passos

Limitações:

- Falhas e lacunas nos dados de GPS.
- Limitação temporal (dados de poucos meses).
- Cobertura parcial de sensores de tráfego.

Próximos passos:

- Ampliar para mais cidades e períodos.
- Integrar dados de transporte ferroviário.
- Aplicar modelos de previsão em tempo real.

Conclusão

Análise mostrou que **chuva e picos de tráfego** são fatores decisivos na pontualidade e tempo de deslocamento.

A aplicação de **Ciência de Dados** permite:

- **Monitorar, prever e planejar** a operação do transporte público.
- Apoiar **decisões inteligentes** nas cidades.