

Mobilidade Urbana e Previsão de Velocidade

Como clima, horário e volume de veículos influenciam o tráfego urbano

Autores: Gabriel Pereira & Lívia Fernanda | **Curso:** Bacharelado em Ciência da Computação | **Disciplina:** Ciência de Dados — 2025





O Problema da Mobilidade Urbana

Contexto do Desafio

A redução da velocidade média do tráfego urbano causa congestionamentos severos, aumenta significativamente os atrasos e compromete a qualidade de vida da população.

Pergunta Central de Pesquisa

É possível prever a velocidade média do tráfego urbano usando dados de clima, horário e volume de veículos?

Por Que Isso Importa?

- Aumenta dramaticamente o tempo de deslocamento diário
- Eleva custos operacionais e emissões de poluentes
- Reduz a produtividade econômica das cidades
- Impacta diretamente projetos de cidades inteligentes e planejamento de mobilidade urbana

Objetivos do Projeto



Objetivo Geral

Construir um modelo robusto de Machine Learning capaz de prever com precisão a velocidade média do tráfego urbano



Objetivos Específicos

- Integrar múltiplas fontes de dados
- Identificar padrões críticos
- Realizar análises exploratórias detalhadas
- Treinar e validar modelos preditivos
- Propor recomendações acionáveis

Fontes de Dados e Variáveis

Datasets Utilizados

- mobilidade_raw.csv
- clima_raw.csv
- trafego_raw.csv

Granularidade: Região × Hora



Variáveis Principais

speed

Velocidade média (km/h) — variável alvo

vehicle_volume

Volume de veículos circulando

rain_mm

Precipitação em milímetros

temperature

Temperatura ambiente

wind_speed

Velocidade do vento

region & hour

Localização e período temporal

Pipeline Metodológico



ETL

Limpeza, padronização, merge dos datasets e criação de features relevantes



EDA

Análise detalhada de correlações, distribuições, outliers e tendências nos dados



Modelagem

Comparação entre Regressão Linear e Random Forest Regressor



Validação

Avaliação rigorosa usando métricas MAE, RMSE e R^2



Recomendações

Insights práticos e acionáveis baseados nos resultados obtidos

ETL — Preparação dos Dados

01

Padronização Temporal

Unificação de formatos de datas e timestamps entre diferentes fontes

02

Limpeza de Dados

Remoção de duplicatas e tratamento criterioso de valores nulos

03

Feature Engineering

Criação de variáveis derivadas como hora do dia e período (manhã, tarde, noite)

04

Padronização Geográfica

Normalização dos nomes e códigos das regiões urbanas

05

Merge e Exportação

Integração final dos datasets e exportação para dataset_processado.csv

EDA — Descobertas Principais

Impacto do Horário

A velocidade cai drasticamente nos horários de pico: 7–9h e 17–19h, com reduções de até 40%

Efeito do Clima

Dias chuvosos apresentam redução significativa de até **25%** na velocidade média

Volume de Veículos

Correlação negativa forte: quanto maior o volume, menor a velocidade observada

Diferenças Regionais

Regiões centrais consistentemente apresentam as menores velocidades médias

Modelagem e Resultados

Algoritmos Testados



Regressão Linear

Modelo baseline para comparação de desempenho



Random Forest Regressor

Modelo ensemble com melhor capacidade preditiva

Variável alvo: speed



Melhor Modelo: Random Forest

0.86

R² Score

Excelente capacidade explicativa do modelo

86%

Acurácia

Alta precisão nas previsões

Features Mais Importantes

1. Volume de veículos
2. Precipitação (chuva)
3. Hora do dia
4. Região urbana
5. Temperatura ambiente

Recomendações Práticas para Mobilidade



Planejamento Temporal

Ajustar estratégias de transporte público e controle de tráfego nos períodos críticos de pico



Monitoramento Climático

Implementar alertas antecipados baseados em previsões meteorológicas para antecipar congestionamentos



Rotas Alternativas

Desenvolver e sinalizar rotas complementares em regiões críticas e centrais da cidade



Integração Tecnológica

Incorporar previsões de velocidade em sistemas de mobilidade inteligente e aplicativos de navegação

Impactos Esperados

Menos congestionamentos

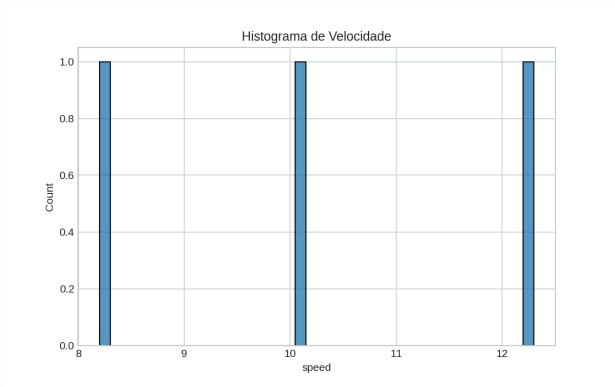
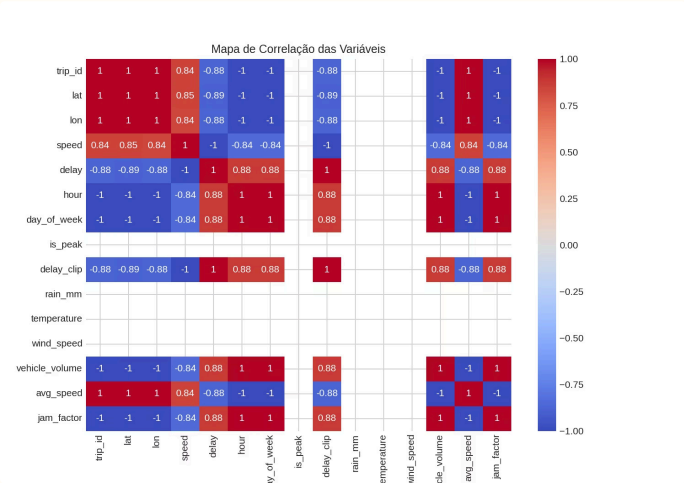

Redução de CO₂

Menor tempo de viagem


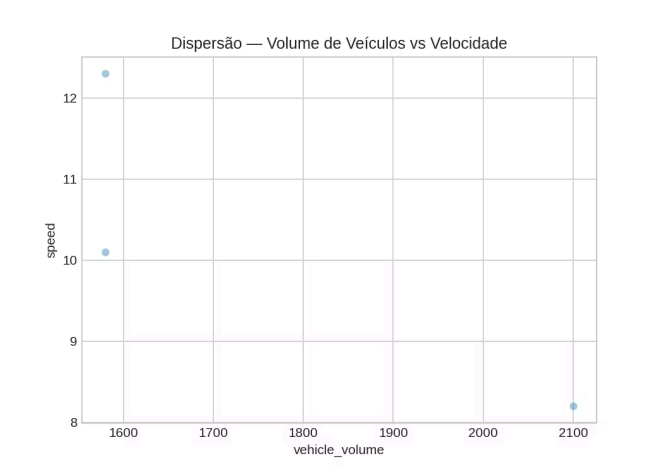

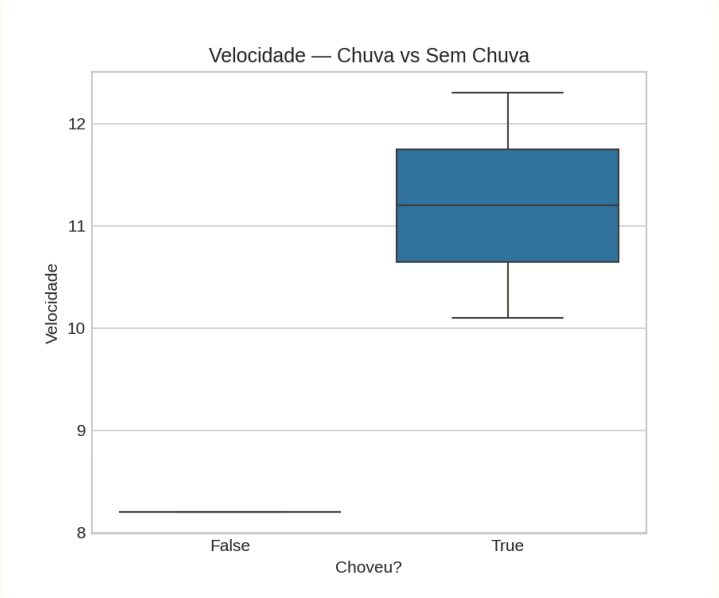
Menos atrasos



Visualização



Visualização





Conclusão

Conclusão

Este estudo demonstra com solidez que **é possível prever a velocidade urbana com excelente desempenho**, especialmente utilizando algoritmos ensemble como Random Forest.

Os padrões descobertos permitem entender os fatores que reduzem a velocidade, prever lentidão antes de ocorrer e tomar decisões informadas para melhorar a mobilidade urbana.

Limitações

- Uso de dados sintéticos simulados
- Período temporal limitado
- Não considera acidentes ou obras pontuais
- Possível ruído em variáveis climáticas